# 摘要

醫生在執行手術時常需要瀏覽病人的醫療影像來確認病人的患病部位，在講求無菌原則的手術室 中，執刀醫師手動操作視窗可能增加感染風險，由旁觀護理師操作則可能造成溝通上的誤會，影響手 術進行。因此，本計畫提出利用電腦視覺與深度學習實作 PACS 系統醫療影像的零接觸遠距操作系統， 讓手術室醫師能以非接觸的方式自行直接操作醫療影像。首先，分析醫師在動手術時可能會使用的各種 PACS 系統醫療影像操作，並設計直覺式且容易辨識的手勢動作。第二，訓練手勢辨識的 LSTM 深 度學習模型，以處理醫師操作醫療影像一連串動作的序列資料。第三，利用 MediaPipe 機器視覺即時 捕捉手勢特徵，並利用 ROI 技術增加影像處理精確度，以及使用 k-means 分群演算法處理醫療手套 顏色問題，以達到即時手勢辨識功能。最後，結合語音辨識功能以提高醫療影像操作的正確性，並使用 PyAutoGUI 呼叫 DICOM Library 之 API，模擬實測 PACS 系統的零接觸遠距操作。



**關鍵詞**：機器視覺、深度學習、軟體開發、手勢辨識、



# Abstract

During operation, surgeons often need to view medical images to aid the operation. However, in a sterile environment, direct interaction with the display could increase the risk of infection, while relying on a nurse to operate the system may lead to communication errors, potentially disrupting the surgery. We propose a contactless system for operating PACS (Picture Archiving and Communication System) medical images using computer vision and deep learning, enabling surgeons to manipulate medical images without physical contact. We begin by analyzing various image manipulating operations that surgeons may use during surgery and designing intuitive, easily recognizable hand gestures as commands for such operation. Next, an LSTM (Long Short-Term Memory) model is trained to recognize these gestures. Third, MediaPipe is employed for real-time hand feature capture, incorporating ROI (Region of Interest) technique to reduce background noises. Additionally, k-means clustering is used to identify medical glove color for image preprocessing. Finally, we integrate voice recognition to the system to further enhance command accuracy. PyAutoGUI is also utilized to interface with I/O device APIs, simulating interactions with actual PACS system APIs.



**Index Terms**: Computer Vision, Deep Learning, Software Development, Sign Recognition


# 一、研究動機與目的

手術部位感染(SSI)為手術併發症的最主要原因，佔院內感染比例 14~17%，對於手術病患更是高達 38%的佔比[1,2]。因此，執刀醫師必須儘量少接觸與手術無關之物品，手術室也執行嚴格的無菌原則。X 光、電腦斷層攝影(CT)、磁共振成像(MRI)等是現代醫療不可或缺的醫療影像工具，醫師執行手術時經常需要參考病人的醫療影像作為輔助，目前這些醫療影像通常使用 DICOM 儲存格式進行處理、儲存、和傳輸。DICOM 檔案格式[3]協助整合同一病人的各種檔案，可節省檔案管理和保存的成本，而且所使用的 TCP/IP 協定也可達成不同裝置間的檔案傳送。醫療影像擷取與傳輸系統(PACS)[4]以 DICOM 協定為基礎，可以在不同的醫學影像器材取得影像，並實現院內或跨醫院的傳輸，醫師可在辦公室的電腦瀏覽病人的資料，也能在執行手術時觀看病人的醫療影像作為輔助。目前手術室中，若持刀醫師需利用 PACS 系統參考病人的醫療影像時，為避免接觸感染或打斷手術，通常由旁觀醫師或護理師協助操作，但是這種做法不但浪費醫療人力，也可能因彼此溝通不良或耗費時間而增加手術風險。根據研究顯示[5]，手術時間越長，感染的風險也越大，而且，手術室中的人員動線都有嚴格的規定，若能簡化手術室內的工作，減少人員的分配，也能讓手術執行更有效率。因此，如何讓手術室中的持刀醫師能以非接觸的方式自行操作和觀看醫療影像，不需要再透過與其他人溝通以進行間接操作是一個重要課題[6]。

為解決前述問題，本研究計畫利用電腦視覺與深度學習技術，實作針對 PACS 系統醫療影像瀏覽視窗的零接觸遠距操作系統，讓手術室醫師能以非接觸的方式自行直接操作醫療影像，主要計畫內容包括：

1. 分析醫師在動手術時可能會使用的各種 PACS 系統醫療影像操作，並設計直覺式且容易辨識的手勢動作，以供遠距自動辨識。

2. 訓練手勢辨識的 LSTM 深度學習模型，以處理醫師操作醫療影像一連串動作的序列資料，提高手勢辨識準確度。

3. 利用 MediaPipe 機器視覺即時捕捉手勢特徵，並利用 ROI 技術增加影像處理精確度，以及使用 k-means 分群演算法處理醫療手套顏色問題，以達到即時手勢辨識功能。

4. 手勢辨識結合語音辨識功能，提高醫療影像操作的正確性，並使用 PyAutoGUI 呼叫 DICOM Library 之 API，模擬實測 PACS 系統的零接觸遠距操作。

本研究計畫以 MediaPipe 抓取手部位置以及 LSTM 模型訓練辨識手勢實作，並輔以語音控制讓使用者可以正確且流暢地進行操作。醫師動手術的過程中有可能需要進行下列的醫療影像操作，本計畫實作下列的醫療影像零接觸遠距操作功能讓手術室醫師能以非接觸的方式自行直接操作：

- 平移影像：以上下左右方式移動影像位置，使欲觀察之部分顯示在螢幕中心處。
- 縮放：將影像放大縮小，可觀察影像細節。
- 調整窗位：窗位是圖像顯示過程中代表圖像灰階的中心位置，因醫療影像大多是灰階圖，以灰度表示各部位對 X 光的吸收程度，黑影表低吸收區，如肺部；白影表高吸收區，如骨骼。灰度共有 256 種，但人眼只能分辨出 16 種，故若醫師需要觀察一組織間的細微差別，則須調整至該組織的窗位，即調整灰階圖片使影像中的差異更明顯。
- 旋轉：順時針或逆時針旋轉影像進行觀察。
- 選取影像：瀏覽 DICOM 檔案中的不同幀(Frame)中的切片(Slice)或選取另一個幀影像。
- 放大鏡：放大觀察特定區域的影像。

## 二、相關文獻回顧

一、手勢辨識之相關研究

手勢辨識通常是透過資料手套方法以硬體偵測手部關節位置、手指間距離及關節傾斜、旋轉的角度來輔助完成，或是以機器視覺和影像處理方法建立手部模型或擷取手部輪廓方式來達成[7]。王國榮[8]曾使用 Cyber Glove 裝置擷取 18 個感應器回傳數據並以六種灰關聯度方法、類神經網路，如倒傳遞網路(BPN)及放射式基底函數網路(RBFN)、以及隱藏式馬可夫模型等多種方法訓練辨識 15 個動態手勢及 30 個靜態手勢。其中以結合灰關聯度方法與類神經網路架構的距離灰關聯度網路(DGRN)辨識下 30 個靜態手勢、15 個動態手勢的辨識率皆達到 100%。

手勢辨識的機器視覺方法主要有幾種做法，其一為實驗者在手上穿戴容易擷取特徵的手套或指套，以機器視覺抓取這些特徵，並將這些特徵轉為向量描述手部位置資訊。Davis 等人[9]以清楚顏色的指套作為特徵，獲得向量後以有限狀態機與向量模型查表對比，實驗中七種手勢在十次辨識測試中僅失敗四次。其二為擷取包含手部影像並用影像處理去除雜訊並使手部特徵突出。Huang 等人[10]以機器視覺擷取手部影像並以影像處理去除雜訊，並使用主成分分析(PCA)及隱藏式馬可夫模型(HMM)訓練模型，並以改良的 Hausdorff 距離輔助模型判斷。對於輸入的測試資料以 Viterbi 演算法對模型進行比對。在測試的 18 種手勢中，這種方法可達到約 90%的成功率。Gupta 等人[11]也以影像處理獲得手部輪廓，並以局部化輪廓序列辨識手勢，雖有 95%以上的準確率，但卻相當耗時，需 20~30 秒辨識手勢。Du 等人[12]則在影像處理過的手部上擷取重心並在輪廓擷取關鍵點。此方法以人體手部可能自然彎曲範圍為依據判斷關鍵點為指尖或指根，並以有限狀態機判斷，可以成功辨別出代表 1~8 的手勢。

MediaPipe 是 Google Research 開發的一套函式庫及工具[13]，可讓使用者在自行開發的人工智慧及機器學習程式上快速套用，並支援嵌入式設備、移動裝置及後端服務器等平台，也支援如 C++、Java、Python 等多種語言。其提供多種模型可應用於不同情形，某些模型也提供一定程度的客製化空間。目前有提供的模型有：物件偵測、手部偵測、臉部偵測、姿勢偵測等。手部偵測模型[14]在觀察的手部中擷取 21 個手部的 3D 關鍵點，由這些關鍵點描述手部行為，本模型由約 3 萬張真實世界

照片訓練，精準度可高達 95.7%，也能判斷出少數被遮蔽的關鍵點。每個關鍵點都具有 X、Y、Z 座標，這些具有立體深度的節點可在 3D 環境下做出各種不同的應用，其節點的資訊也可用於訓練模型以辨識各節點位置組合代表之資訊。

二、深度學習之相關研究

深度學習是機器學習的其中一種，透過針對資料的特徵值進行多個處理層的學習，其優點為可以利用非監督式或半監督式的特徵學習和分層特徵提取演算法來取得特徵和進行學習。相關研究中使用深度學習訓練 MediaPipe 手部模型辨識手勢的實驗結果比較如表一所示。

表一、使用 MediaPipe 與深度學習技術實作手勢辨識比較表

| 使用技術 | 準確率 | 資料集 |
|---|---|---|
| MediaPipe + SVM[15] | 99% | 網路資源 ASL dataset |
| MediaPipe + CNN[16] | 99% | 自行產生 ASL 手勢 |
| MediaPipe + LSTM[17] | 99% | 自行產生 ASL 手勢 |

支持向量機(SVM)是一種分類器，主要是以支持向量找出可以最有效分類資料的決策邊界。Chandwani 等人[15]在研究中使用多種分類器模型測試 MediaPipe 手勢辨識，其中，SVM 模型達到 98.975%準確率；Random Forest 模型達到 97.5%準確率；Decision Tree 模型達到 91.52%準確率；Naïve Bayes 模型達到 50.84%準確率；KNN 達到 96.39%準確率。

卷積神經網路(CNN)由多個卷積層和頂端的全連通層組成，並透過池化層不斷地減小資料的空間大小，以降低參數的數量和計算量。CNN 的原理為在輸入的圖像矩陣中比較多個局部特徵，並篩選計算整張圖像中相似特徵的數量，最後於全連接層將特徵資訊化為票數，決定最後的輸出。這種做法可以在圖像資訊旋轉、平移、縮放後仍能正確判斷正確標籤。CNN 主要處理圖像資訊，而非序列資料，但也曾有研究者使用 CNN 實作自然語言處理(NLP)。Kim 等人[18]以矩陣表示句子。矩陣的每一行對應一單字或符號，而在矩陣上擷取特徵也變為擷取數行單字，其卷積核的高度即一次掃過的單字量，實作以 CNN 處理序列資料。而 Rupesh 等人[16]則是把 MediaPipe 手部模型擷取的關鍵點轉為一維陣列並由 CNN 模型處理時做手勢辨識，並達到 99.95%的準確率。

LSTM[19]是一種基於時間循環神經網路(RNN)的設計，LSTM 改善 RNN 在長期記憶上的不足，並解決 RNN 梯度反傳過程產生的梯度消失問題，且在複雜的序列預測任務中表現優異，如機器翻譯、語音識別等。Sundar 等人[17]用 LSTM 模型訓練 MediaPipe 手部模型關鍵點資料，成功辨識 ASL 美國手語字母且達到 99%準確率。

## 三、實驗流程規劃

本計畫利用電腦視覺與深度學習實作 PACS 系統醫療影像的零接觸遠距操作系統，讓手術室醫師能以非接觸的方式自行直接操作醫療影像。其主要內容包括：(1)分析醫師在動手術時可能會使用的各種 PACS 系統醫療影像操作，並設計直覺式且容易辨識的手勢動作。(2)訓練手勢辨識的 LSTM 深度學習模型，以處理醫師操作醫療影像一連串動作的序列資料。(3)利用 MediaPipe 即時捕捉手勢特徵，並利用 ROI 技術增加影像處理精確度，以及使用 k-means 分群演算法處理醫療手套顏色問題，以達到即時手勢辨識功能。(4)結合語音辨識功能以提高醫療影像操作的正確性，並使用 PyAutoGUI 呼叫 DICOM Library 之 API，模擬實測 PACS 系統的零接觸遠距操作。圖一為本實驗設計的系統架構圖。

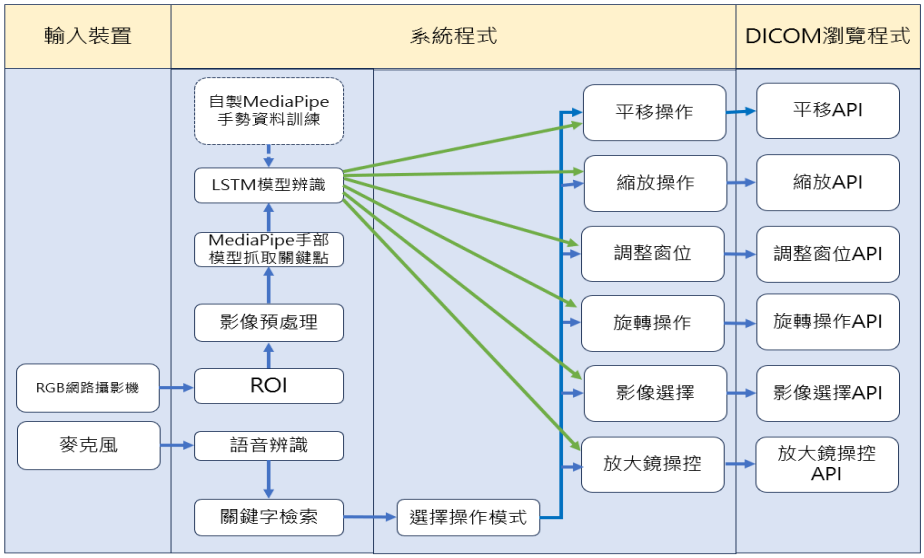


圖一、系統架構圖

## 四、設計相應手勢動作

PACS 系統的醫療影像操作功能如圖二的 DICOM Library 系統[20]所示，經由訪問多位手術室醫師後可以歸納整理出，醫師在手術室內進行手術時，可能會使用到下列六個醫療影像操作功能，包括：

1. 平移功能：對目前選取的影像進行二維的平移，以觀察感興趣之區域。
2. 縮放功能：等比例縮放影像，放大感興趣之區域以觀察影像的細節。
3. 調整窗位功能：調整影像灰階的中心位置，可放大不同灰度影像的視覺差異。
4. 旋轉功能：對影像逆時針或順時針旋轉。
5. 選取影像功能：在同個 DICOM 檔案中選取欲觀察之影像，或影像的切片(slice)。
6. 放大鏡功能：放大小部分影像方便觀察細節。

圖二、DICOM Library 之醫療影像操作功能

如果針對六項功能的每個操作和移動方式都設計相應手勢，使用者在操作時將需要記住數量龐大的手勢動作，會造成操作上的不便。因此，本計畫先對於 6 個醫療影像操作功能設計成圖三的 6 種容易記憶的基本手勢，再利用此 6 種基本手勢進行直觀的不同動作序列，例如，手勢一代表平移功能，用手勢一做由下往上移動的動作代表由下往上平移，而手勢一做由上往下移動的動作則代表由上往下平移；手勢二代表縮放功能，用手勢二做由下往上移動的動作代表放大，而手勢二做由上往下移動的動作則代表縮小等。因此，在使用者的視角中，只需要記得這 6 種基本手勢並做上、下、左、右的移動，就能操作整個系統。而在程式設計中，模型真正辨識的輸入為一連串的關鍵點資料，代表一段時間的手部動作位置變化。醫療影像操作的 6 項功能中，需要辨識四個手勢移動方向的有 4 種，另外 2 種只須辨識兩個手勢移動方向，所以真正輸入模型辨識的動作共有 20 種。

手勢一：食指伸出，其他手指收起　手勢二：食指、中指伸出，其他手指收起　手勢三：食指、中指、無名指伸出，其他手指收起　手勢四：食指、中指、無名指、小指伸出，其他手指收起　手勢五：五指張開　手勢六：五指收起

圖三、本計畫使用之六種基本手勢

## 五、訓練 LSTM 深度學習模型

由於本計畫需要使用基本手勢進行一連串的動作序列，例如手勢一從左向右移動。因此，適合使用可處理長時間記憶，且用於處理序列資料的 LSTM 模型來搭配 MediaPipe 手部模型進行手勢辨識的實作，本計畫 LSTM 模型的訓練流程如圖四所示。

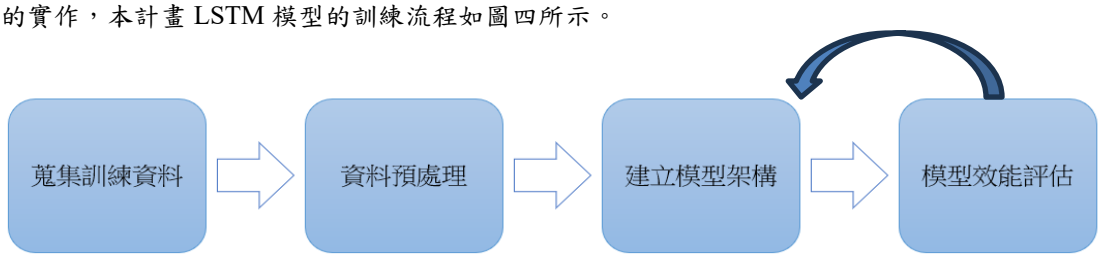


圖四、訓練 LSTM 模型流程圖

### 1. 蒐集訓練資料

本計畫自行生成訓練資料，所需辨識動作包含六種手勢的不同移動方向序列共 20 種，預計以 RGB 網路攝影機錄像 30 幀影片，每種動作 30 部影片，總共 600 部影片做為資料集。再對每幀圖像擷取關鍵點前，需先將 OpenCV 擷取圖片的 BGR 格式轉換為 RGB 格式，再由 MediaPipe 手部模型抓取關鍵點並轉為 NumPy 矩陣儲存，並以三十份矩陣資料為一辨識單位，如圖五所示。

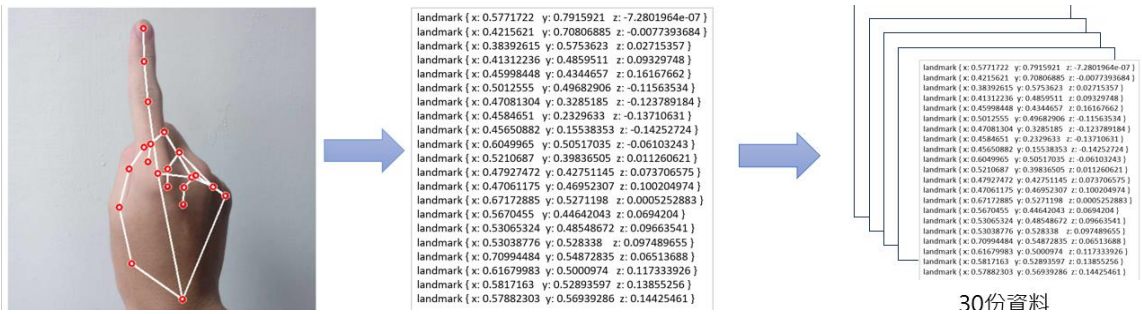


圖五、MediaPipe 抓取手部關鍵點資料

本系統只用一隻手進行操作，故每幀影像只需擷取一隻手的 21 個關鍵點。由於每張照片有 21 個關鍵點，每個關鍵點以(x, y, z)描述，故每幀的的資料為維度(21, 3)的矩陣，每部影片的資料為 30 份維度為(21, 3)的資料矩陣。資料集總共有 600 份影片資料，每份資料維度為(30, 21, 3)。

**2. 資料預處理**

使用 LSTM 模型處理關鍵點資料需先轉換成序列資料，故儲存資料時需將維度為(21, 3)的子矩陣展平成維度為(63)的一維矩陣儲存，此時，全資料集的維度為(600, 30, 63)，代表 600 部影片，每部 30 幀，每幀包含 63 個關鍵點資料。對於全部 600 份資料，分別賦予標籤，並以一維矩陣儲存。將標籤資料輸入 LSTM 模型前，也需將這些資料進行預處理，以提升訓練及辨識效能。由於四種手勢間並沒有大小關係，採用獨熱編碼(One-Hot-Encoding)，假設共有 N 種狀態，則將類別轉換成 N 行，值以二位元表示，若某列資料存在，則代表此資料之行以 1 表示，其餘必須以 0 表示，每列只能有一值為 1，本計畫之標籤轉換如圖六所示。

| Label |
|---|
| 手勢一由左往右 |
| 手勢一由右往左 |
| 手勢一由上往下 |
| 手勢一由下往上 |
| … |

| 手勢一由左往右 | 手勢一由右往左 | 手勢一由上往下 | 手勢一由下往上 | … |
|---|---|---|---|---|
| 1 | 0 | 0 | 0 | … |
| 0 | 1 | 0 | 0 | … |
| 0 | 0 | 1 | 0 | … |
| 0 | 0 | 0 | 1 | … |

圖六、本計畫的獨熱編碼轉換圖

**3. 建立模型架構**

本計畫使用 TensorFlow 的 Keras API，建立一個包含 LSTM 和全連接層的深度學習模型架構如圖七。此結構允許模型捕捉數據中的時間相依性，在連續動作識別等任務中相當重要，其主要結構包括(1)LSTM 層、(2)線性整流層、(3)全連接層。

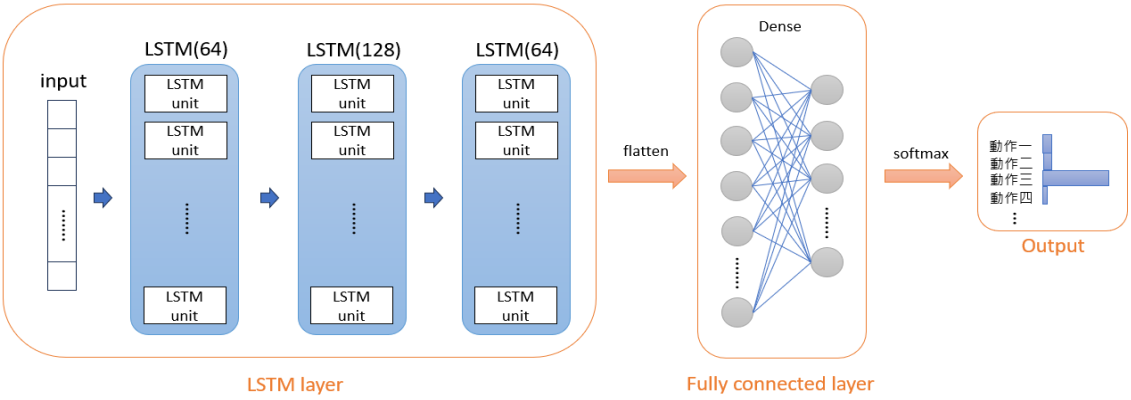


圖七、LSTM 模型架構

(1) LSTM 層

LSTM 層由三層 LSTM units 組成，三層的單元數分別是 64、128、64，在第一層使用較少單元數以獲取資料的低層特徵，如短期依賴性。在第二層增加單元數量以在這些低層特徵上提取，可學習更複雜的特徵及模式，也能學習資料的長期依賴性。第三層用於整合或化簡上一層提取出的特徵。這種做法可以幫助類神經網路更容易進行層次化提取資料，並學習數據中的時間相依性，來辨識一段時間內的連續動作。

(2) 線性整流層

線性整流層使用線性整流(ReLU)：$f(x) = \max(0, x)$，作為這一層的激勵函式，可以增強判定函式和整個類神經網路的非線性特性，而本身並不會改變 LSTM 層。如此可以將類

神經網路的訓練速度提升，而且並不會對模型的泛化準確度造成影響。每個 LSTM 層之後都會有線性整流層進行作用。

(3) 全連接層

全連接層架設於類神經網路模型的最後層，將從該層之前的幾個特徵抽取層獲得的特徵表達向量映射到最終的 softmax 函式做分類，softmax 函式可以將輸出數值轉為概率分布。

**4. 模型效能評估**

待模型訓練完成後，本計畫使用視覺化圖像根據以下兩點觀察模型效能，經過模型效能評估，以決定是否此模型可以達到標準或是需要再重新設計架構。

(1) 混淆矩陣

混淆矩陣用於監督學習，可直覺看出模型是否將兩個不同的類混淆，而正確的預測都會在對角線上。從混淆矩陣上可以觀察到以下四種評估值：

- 準確率(Accuracy)：模型正確預測的樣本數占總樣本數的比例。
- 精確率(Precision)：模型在預測為正例的樣本中有多少是真正的正例。
- 召回率(Recall)：實際正例中有多少被模型成功預測為正例。
- F1 分數(F1 score)：精確率和召回率的調和平均數，可以用來綜合考慮兩者。

(2) 損失函數值和準確率圖表

此圖表以迭代次數(epochs)為 X 軸，損失函數值或準確率為 Y 軸，以及兩條曲線代表訓練集及測試集的損失函數值或準確率。此圖表可以觀察出模型是否存在過度擬合(overfitting)或欠擬合(underfitting)等問題，以及發生的時間。過度擬合指模型對於訓練集資料準確率高，對測試集資料準確率卻明顯下降，模型可能過度訓練；欠擬合指模型對於訓練集與測試集資料準確率都很差，模型可能訓練不完整。

## 六、即時手勢辨識處理

本計畫在手術室中的即時手勢辨識，利用 RGB 網路攝影機輸入手勢動作，並由 MediaPipe 手部模型抓取一段時間內手部移動的關鍵點，然後將這些關鍵點序列添加到 sequence 中，即時將關鍵點資訊輸入預先訓練好的 LSTM 模型進行手勢判斷。為提高即時手勢辨識的準確性，本計畫進行感興趣區域(ROI)和手套顏色處理的兩項影像處理工作。

1. 感興趣區域(ROI)

MediaPipe 手部模型會從影像偵測人的手部，背景中的人手仍可能被錯誤偵測，造成使用者無法成功輸入指令或造成無法預期之錯誤。本計畫使用感興趣區域(region of interest，ROI)技術，ROI 為影像處理的技術，用幾何圖形勾勒出需要影像處理的區域，這種做法可以減少處理時間，增加影像處理精確度。本計畫在 RGB 網路攝影機擷取影像時，在使用者大約右手位置劃定 ROI，並只在此區域執行 MediaPipe 手部模型偵測。

2. 手套顏色處理

MediaPipe 手部模型使用內建 CNN 模型偵測人的手部，而此 CNN 模型在擷取影像特徵時會參考人的膚色，但執刀醫師通常會穿戴藍色或白色的手術手套，可能會造成模型無法辨識出手部。如圖八所示，左圖可以觀察到藍色手套的原色圖無法辨識找出手部模型的關鍵點，右圖渲染成近膚色後 MediaPipe 手部模型才能成功辨識並畫出關鍵點。因此，預處理時需調整影像顏色使手套部位接近膚色，惟藍色手套與白色手套所需調整之參數不同，所以在程式執行前會要求使用者在 ROI 展示手套顏色，若手套接近藍色則影像處理會套用藍色轉膚色之參數，白色手套則套用不同參數。

藍色手套影像處理前　　藍色手套影像處理後

圖八、手套影像處理前、後對照圖

擷取顏色方法採利用 k-means 分群演算法，k-means 是將資料以最近的群集中心(首次隨機選一資料)進行分群，並動態更新群集中心直到分群狀況不再變動。此演算法可以應用在找出影像的主色相，作法為把處理影像的每個像素的 RGB 值投影在 RGB 空間中，並把這些資料做分群，當演算法結束時，輸出最大分群的中心點，此點代表之 RGB 值即是影像的主色調，透過要求使用者在程式開始時先展示手套顏色，我們可以確保 ROI 範圍內的主色調跟手套同色。而由於 OpenCV 以 BGR 形式回傳影像，因此處理完之影像還需轉換成 RGB 形式才能以 MediaPipe 模型抓取關鍵點。

## 七、結合語音辨識呼叫 DICOM Library 之 API

為使整個系統操作更流暢並防止錯誤操作，本計畫結合語音辨識功能以雙重確認使用者的操作手勢。系統可利用麥克風接受使用者以語音訊息快速選擇操作功能，再以移動手勢進行操作，當語音辨識出的操作功能和手勢辨識出的操作功能不同時，例如語音訊息是旋轉功能，但移動手勢卻是手勢二(縮放功能)，系統可分辨出使用者發生錯誤指令並提出警示，以提高醫療影像操作的正確性。本計畫利用網路上功能齊全的 DICOM Library 瀏覽程式[20]進行 PACS 系統零接觸遠距操作的模擬實測，當系統確認使用者的醫療影像操作指令後，會使用 PyAutoGUI 呼叫 DICOM Library 相對應之 API 以執行醫療影像操作。

系統在確認完手套顏色後，RGB 相機便會不斷偵測，以 30 幀為一單位即時將使用者影像傳入模型辨識，若這 30 幀資料達到信心指數，則發送對應的信號。在執行手勢的指令前，會先檢查使用只是否語音選擇相應的模式，以防止錯誤輸入。使用者可輸入之語音為「平移、縮放、窗位、旋轉、選取、放大鏡、停止」，語音輸入會實作關鍵詞檢測使操作更流暢。上述前六種指令會開放相應的模式，「停止」指令則會防止任何對影像的動作。除此之外，為防止錯誤操作，在不同模式需要以不同手勢操作。

(1) 平移功能：使用者以圖三的「手勢一」執行操作，以此手勢往上、下、左、右移動，程式傳送相應方向移動的 API，實現平移功能。

(2) 縮放功能：使用者以圖三的「手勢二」執行操作，以此手勢往上、下移動，往上則傳送放大 API，往下傳送縮小 API，實現縮放功能。

(3) 調整窗位功能：窗位調整與平移類似，可在二維平面上任一方向調整。使用者以圖三的「手勢三」執行操作，以此手勢往上、下、左、右移動，程式傳送相應的 API，實現調整窗位功能。

(4) 旋轉功能：使用者以圖三的「手勢四」執行操作，以此手勢往上、下移動，往上則傳送逆時針旋轉 API，往下傳送順時針旋轉 API，實現旋轉功能。

(5) 選取影像功能：DICOM 檔案可能包含多個影像，一影像又可能包含許多切片，故設計以

圖三的「手勢五」執行操作，手勢往上選取上個影像，往下選取下個影像，往左選取上個切片，往右選取下個切片。

(6) 放大鏡功能：使用者以圖三的「手勢六」執行操作，以此手勢往上、下、左、右移動，程式傳送相應 API 移動放大鏡。

雖然上述辨識的動作序列多達 20 種，但使用者只需記住 6 種手勢及移動方向即可完全操作，可以簡單及直覺化地操作系統。

## 八、實驗結果

(一) 模型訓練：

原本計畫書中提出的「以 30 幀的 Mediapipe 左手模型節點在螢幕上的位置」為辨識單位訓練模型在模型訓練以及使用者實際操作上無法獲得預期成果，且有嚴重的 overfitting 情形，如圖九所示，分析可能原因有三者：

1. 各個手勢間的差異過小，如手勢一及手勢二僅有 3 個節點的差別，有 18 個節點重複，如圖十所示。過往研究僅辨識單幀的手勢，能以此方法取得優秀的成果，惟本計畫訓練的模型以連續 30 幀的資料為單位，除手勢差異小外也存在手部移動速度不一，某幾幀抓取不到手部模型造成資料缺失等因素，因此無法準確分辨差異小之不同手勢。
2. 以絕對位置辨識，則每種手勢三十部影片的資料量不夠充足，不足以辨識使用者在任何位置所比出的手勢，要達成原本的應用目的需要更龐大的資料集。
3. 以 30 幀為單位辨識，使用本實驗採用的 30 幀率鏡頭操作，需要 1 秒才能傳送一個指令，違反本計畫設計系統之即時性。

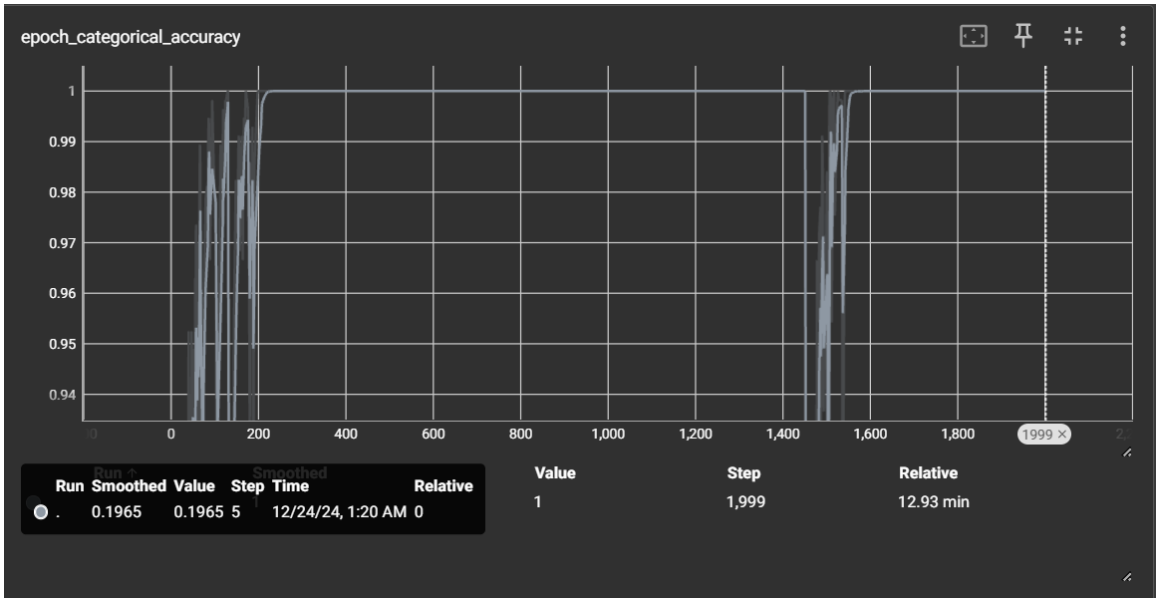


圖九、依照原本資料結構模型訓練過程

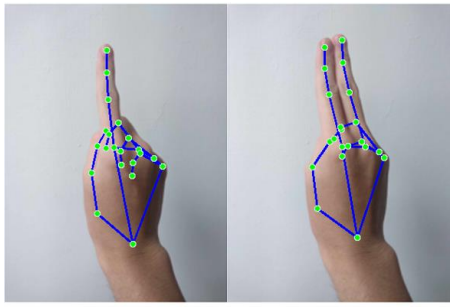

手勢一：食指伸出，其他手指收起　　手勢二：食指、中指伸出，其他手指收起

圖十、手勢一與手勢二之節點差異

基於以上原因，在以達到實用目的且維持原本資料量大小的目標下，我重新定義辨識單位的資料結構，以解決上述問題。新的資料結構以 5 幀為單位，如此僅需 1/6 秒即可進行辨識，並考量到六種手勢間最明顯的差異為手指節點的位置，以及任意位置都能辨識的可行性，重新定義每幀所擷取的資料。新的資料結構擷取手部的移動方向，以及五根手指相對手腕的位置變化，並以此公式定義：$D = [P, F1, F2, F3, F4, F5]$

$$Where: \mathrm{P} = \left[\mathrm{h[0][x]} - \mathrm{h'[0][x]}, \mathrm{h[0][y]} - \mathrm{h'[0][y]}, \mathrm{h[0][z]} - \mathrm{h'[0][z]}\right] \text{ and}$$

$$\mathrm{Fi} = [\mathrm{h[4i][x]} - \mathrm{h'[4i][x]}, \mathrm{h[4i][y]} - \mathrm{h'[4i][y]}, \mathrm{h[4i][z]} - \mathrm{h'[4i][z]}], \mathrm{i} = 1,2,3,4,5$$

其中，h 與 h′定義與節點代表位置如圖十一所示，x, y, z 表三維空間位置。

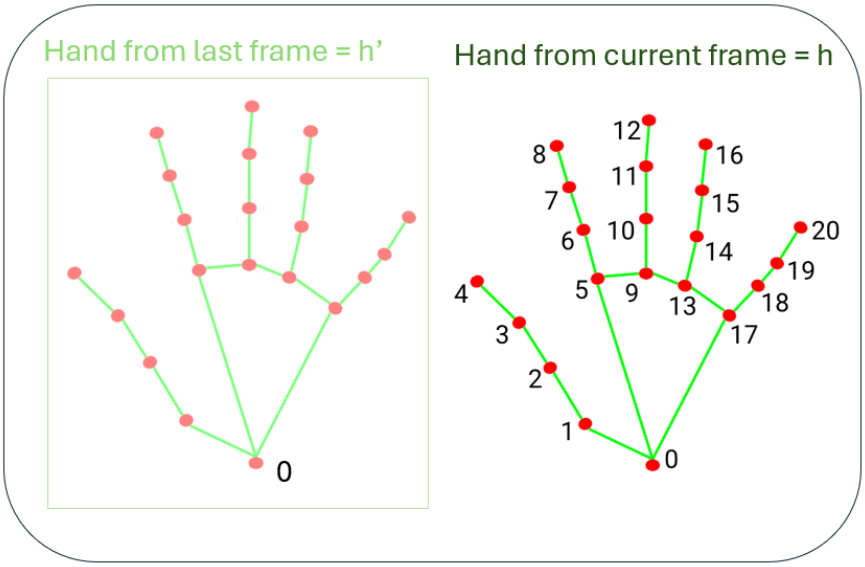


圖十一、公式使用符號輔助圖

本資料結構為 6 個大小為 3 的一為陣列串接，其中 P 代表「用三維向量表示本幀手腕節點對比上一幀手腕節點的移動幅度」，F1~F5 代表「用三維向量表示手指與手腕的相對位置」。新的資料結構僅擷取造成差異的特徵點，將每幀的資料量由 63 個浮點數壓縮至 18 個浮點數，並調整辨識影片之長度，在維持原本資料量的前提下，可將原本每個手勢 30 部影片的資料集擴增至 630 部影片。

針對減少影片長度可能放大雜訊(如：手部模型辨識失敗、使用者手部無法完全以一種方向移動等)，以及以相對位置表示手指無法讓模型學習運動方向的問題。我們由原本讓模型學習時間內節點位置變化所代表之移動方向的方法，改為在資料結構中明確定義手部相較上一幀的移動向量，則模

型僅需學習水平向量或垂直向量增加或減少所代表的方向含意即可。

以新的資料結構，我們對於每種手勢拍攝了各 100 部影片做為資料集，並在 500 次迭代後取得約 99%的辨識率，並在使用者測試中獲得滿意的結果。如圖十二、圖十三與圖十四所示。

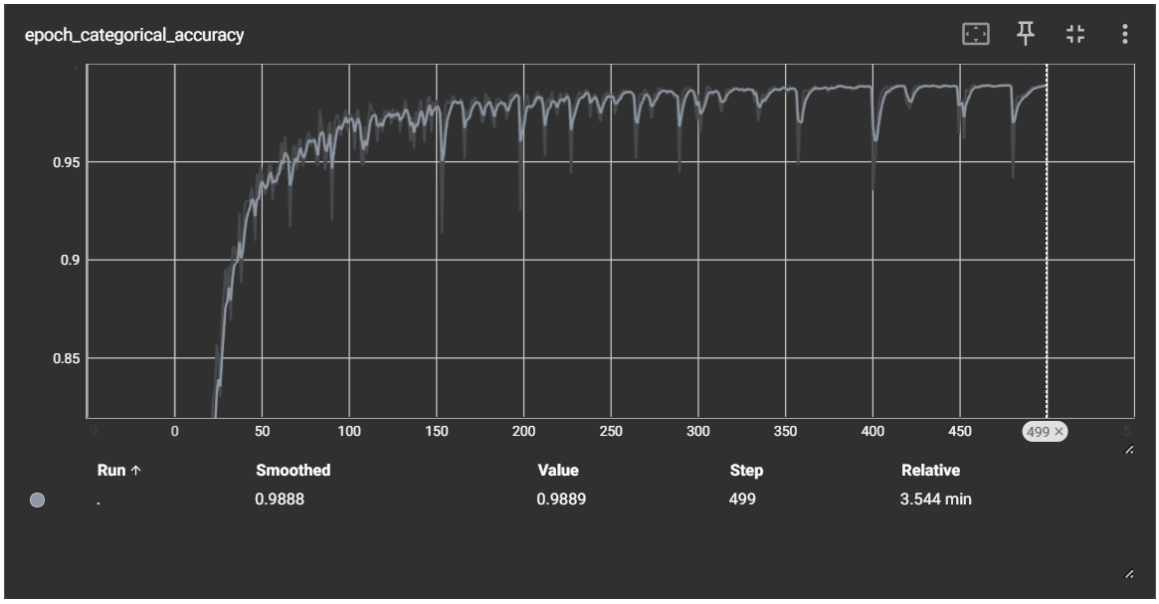


圖十二、模型訓練準確度曲線圖

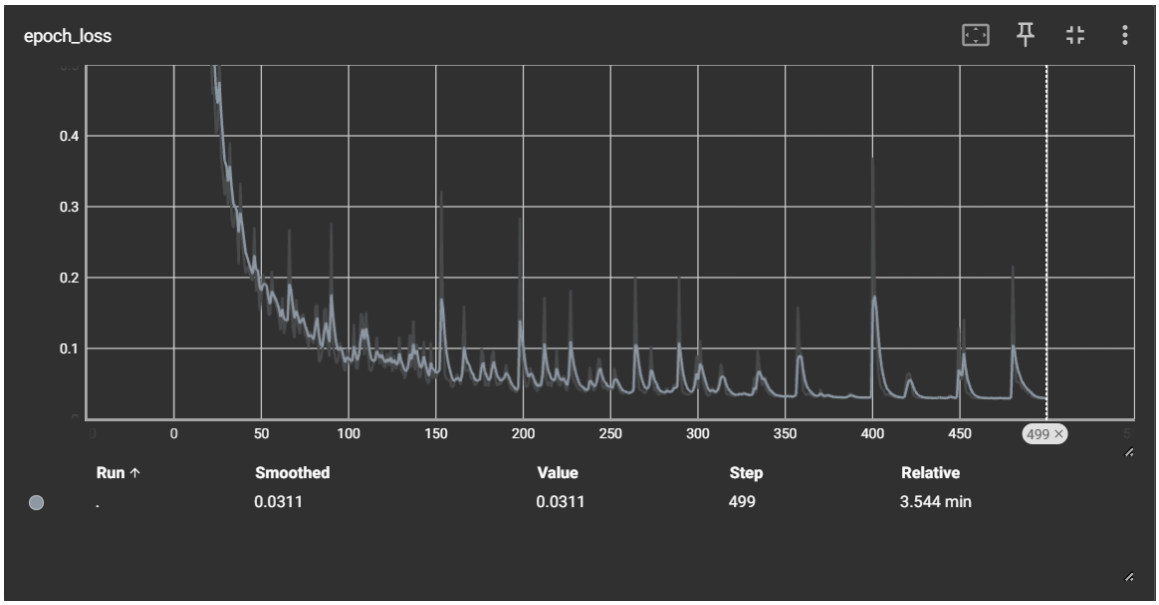


圖十三、模型訓練損失曲線圖

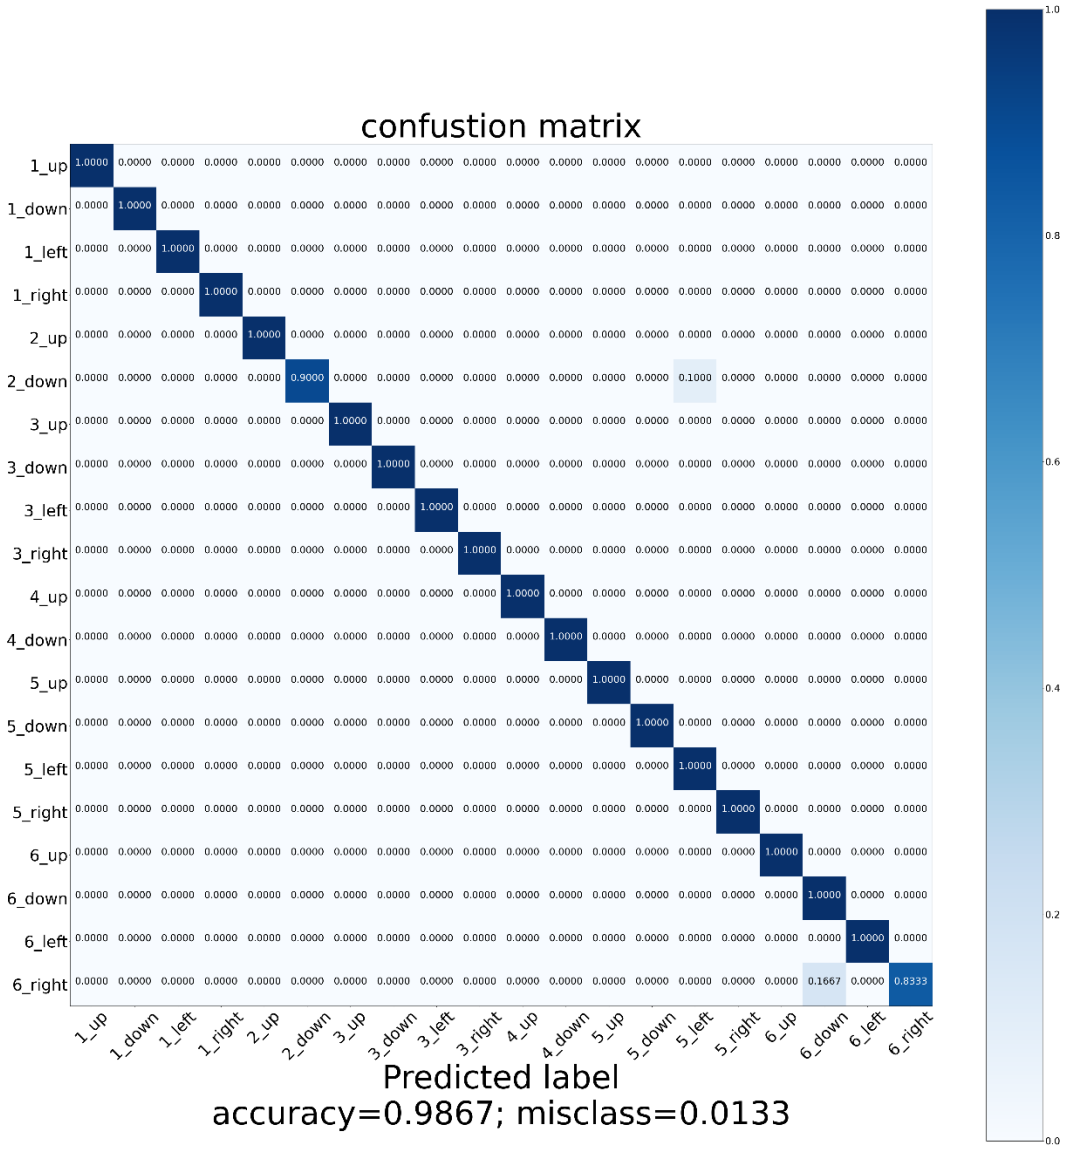


圖十四、模型的混淆矩陣

(二) 以 K-means 演算法取得主要色：

將鏡頭畫面中小塊偵測區的像素由 RGB 色彩空間轉為 HSV 色彩空間，因為其表示法僅需一個像量(Hue)便可判斷顏色之色調，並針對該色調較接近醫療常見的藍色手套與白色手套分別調整渲染參數並將渲染作用在整個鏡頭畫面。其成果如圖十五與圖十六表示。

圖十五、渲染前手套辨識結果

圖十六、渲染後手套辨識結果

可以觀察到，經渲染後，原本無法辨識的手套方可成功辨識。

(三) 語音指令辨識：

以 google 提供的繁體中文套件擷取使用者語音，由於該套件辨識目標是中文的所有單詞語句，我們遇到了該套件會將指令辨識成更常見的中文單字的問題，如：將「平移」辨識成「便宜」。對此，我們的解決方法是將該套件的辨識結果轉為英文拼音，比對七個目標指令轉為英文拼音的字串，並輸出最接近之指令結果。

(四) 軟體整合與 API 串接：

以設計人性化操作介面為目的，我們針對本軟體設計了以下流程：

1. 程式開始運行，使用者鏡頭開啟，使用者須將手套覆蓋在畫面上所畫出的小方格偵測區，程式會倒數 10 秒鐘，並在倒數結束時運行 K-means 演算法抓取主要色；由於我們使用線上 DICOM 操作介面模擬 API 傳遞。我們需要在程式開啟時同時開啟該網站，在抓取主要色的十秒內完成加載。該介面如圖十七所示。

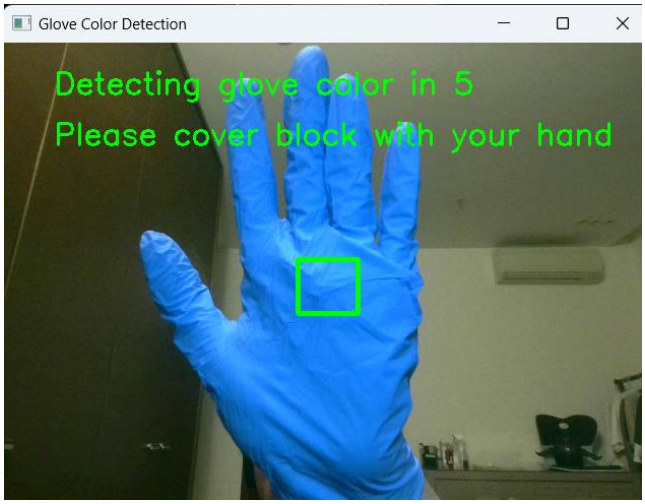


圖十七、手套顏色偵測視窗

2. 10 秒結束後，程式根據手套顏色取得渲染參數，同時開啟負責語音辨識的執行序，此方法可在不堵塞主程式的指令辨識與畫面即時回饋的前提下達成隨時接受麥克風信號的語音辨識。之後，再次開啟鏡頭並執行手勢辨識程式，並以畫面左半區為 ROI 擷取手勢。

3. 主程式將鏡頭擷取的每幀畫面根據參數做渲染並以模型執行辨識，並在以語音選取正確模式後才輸出果。其中，以鍵盤按鍵與滑鼠模擬影像控制 API 之方法如下：

   A. 模式選取：根據語音辨識結果傳送滑鼠點擊訊號，並作用於該模式的圖標位置。

   B. 平移、縮放、窗位、旋轉：檢查模式選取後，根據手勢方向傳遞滑鼠拖曳的指令。

   C. 放大鏡：模式選取時同時傳遞滑鼠按下指令並維持，根據手勢方向傳遞滑鼠移動指令。並在後續選取其他指令時傳遞滑鼠放開指令。

   D. 選擇：檢查模式選取後，根據手勢方向傳遞鍵盤的上、下、左、右按鍵指令。

主程式執行畫面如圖十八、圖十九、圖二十、圖二十一、圖二十二、圖二十三所示：

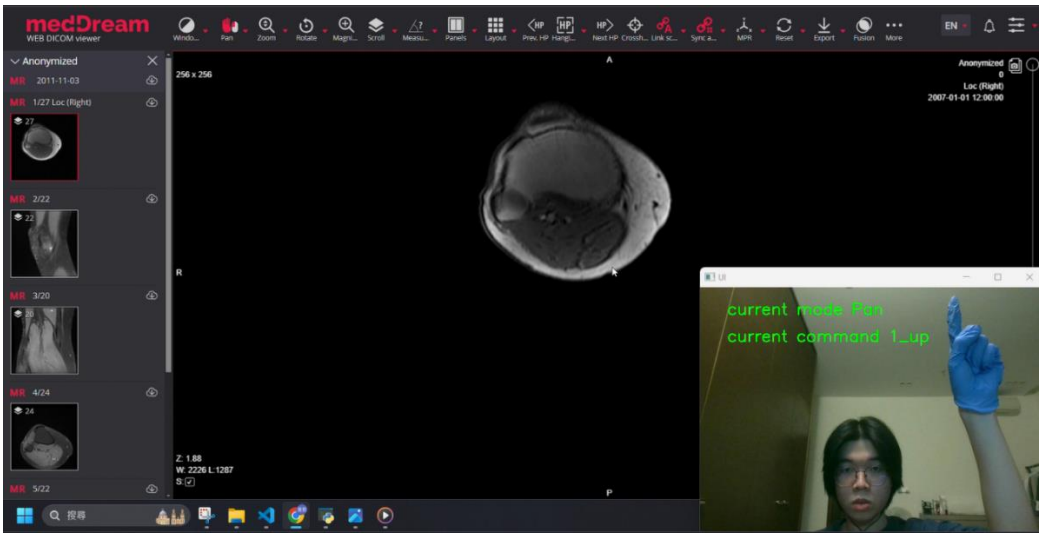


圖十八、程式執行平移指令

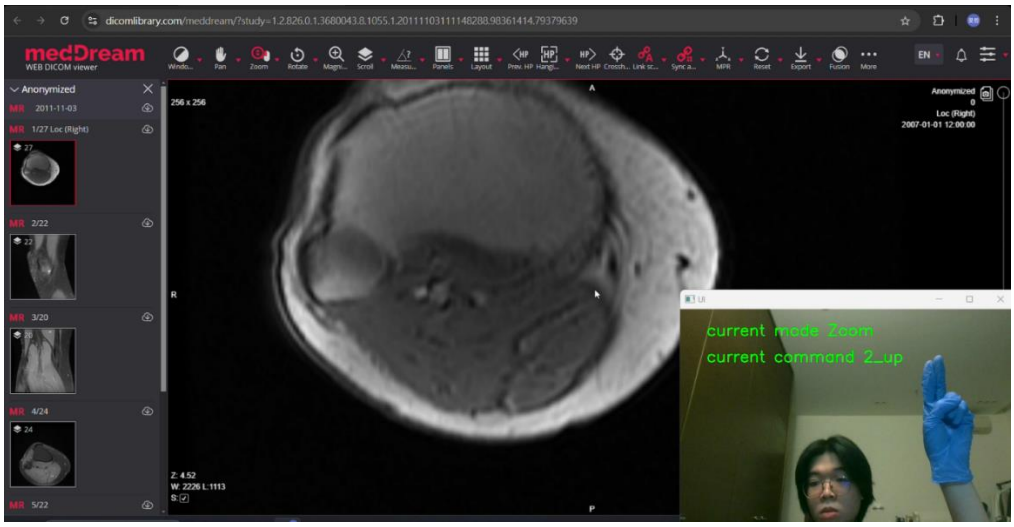


圖十九、程式執行縮放指令

圖二十、程式執行窗位指令

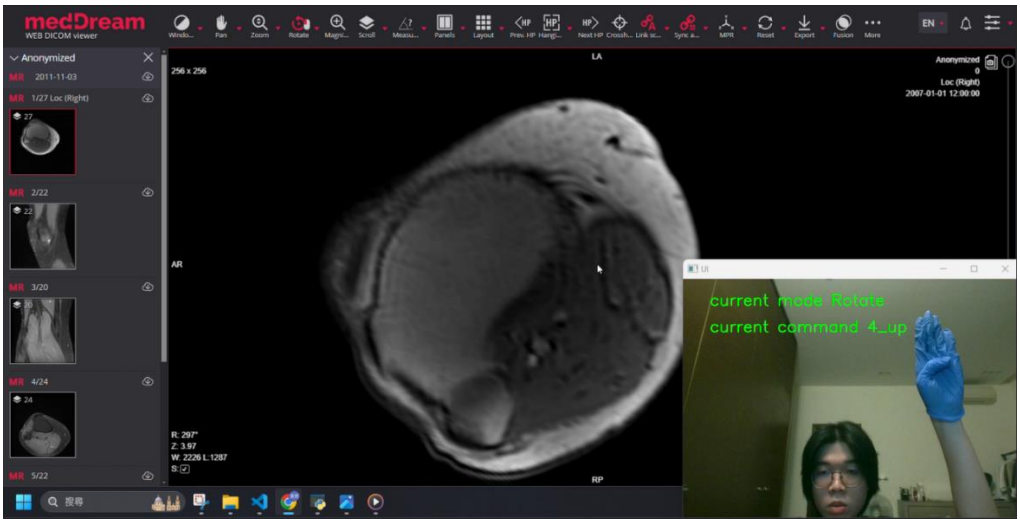


圖二十一、程式執行旋轉指令

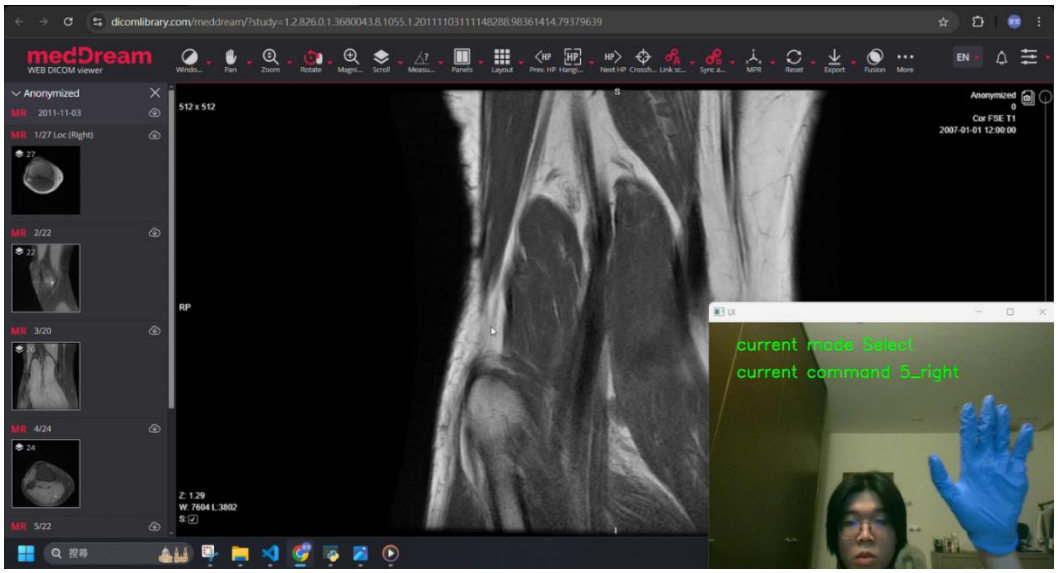


圖二十二、程式執行選擇指令

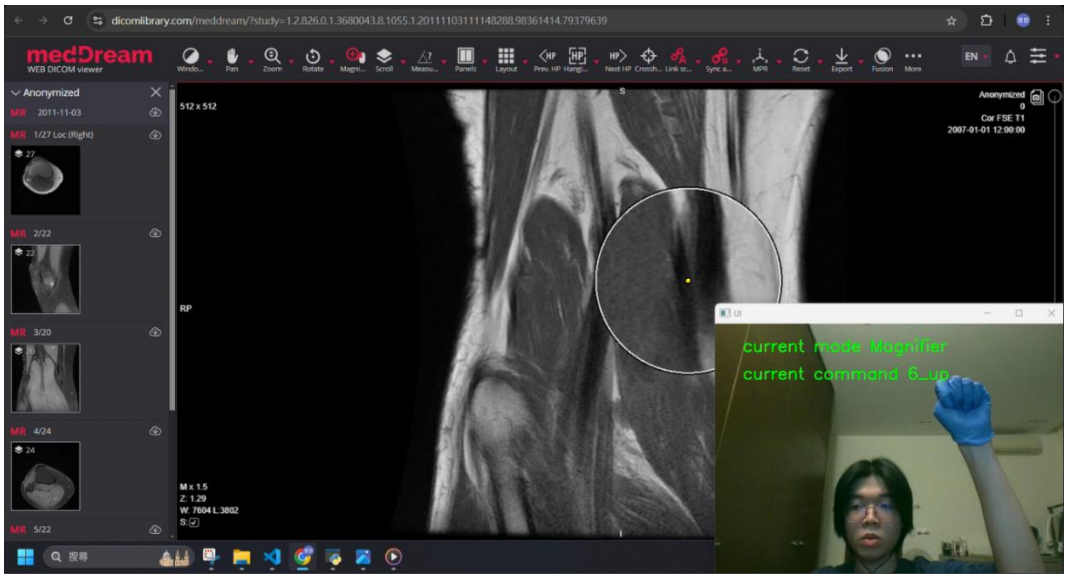


圖二十三、程式執行放大鏡指令

## 九、研究結論與討論

本研究計畫已依照計畫書實作完成各項功能，並利用以下方法改善原計畫所規劃方法的缺陷：

1. 重新定義資料結構，將其改為辨識相對位置，並明確寫出移動像量，簡化模型所需學習內容便可達成相同效果。
2. 將語音辨識的結果與指令做拼音的相似度比對後，輸出最相似的指令，以解決因雜訊或發音問題造成的語音辨識錯誤。
3. 以多執行序等軟體開發技術完善程式，達到使用順暢及即時回饋的目標。

我們將各項功能以軟體開發技術整合，開發出一套方便操作且符合人性的無接觸醫療影像遠端操作系統。即使我們盡量解決遇到的問題，惟由 I/O 設備模擬的 API 傳遞所造成之指令間卡頓無法由軟體方法有效解決。若能串接至可直接呼叫程式內 API 之 DICOM 影像操作系統，程式才有可能

達成預期的無延遲即時影像操作與使用者反饋。

## 十、參考文獻


[1] J.A. Weigelt, B.A. Lipsky, Y.P. Tabak, K.G. Derby, M. Kim, and V. Gupta. Surgical site infections: Causative pathogens and associated outcomes. American Journal of Infection Control, 38(2):112-20, Mar. 2010. doi: 10.1016/j.ajic.2009.06.010.

[2] National Nosocomial Infections Surveillance System. National Nosocomial Infections Surveillance (NNIS) System Report, data summary from January 1992 through June 2004, issued October 2004. American Journal of Infection Control, 32(8):470-85, Dec. 2004. doi: 10.1016/S0196655304005425.

[3] W.D. Bidgood Jr, S.C. Horii, F.W. Prior, and D.E. Van Syckle. Understanding and using DICOM, the data interchange standard for biomedical imaging. Journal of the American Medical Informatics Association, 4(3):199-212, May 1997. doi: 10.1136/jamia.1997.0040199.

[4] N.H. Strickland. PACS (picture archiving and communication systems): filmless radiology. Archives of Disease in Childhood, 83(1):82-6, Jul. 2000. doi: 10.1136/adc.83.1.82.

[5] V. Shahane, S. Bhawal, and U. Lele. Surgical site infections: A one year prospective study in a tertiary care center. International Journal of Health Sciences, 6(1):79-84, Jan. 2012. doi: 10.12816/0005976.

[6] J.H. Tan, C. Chao, M. Zawaideh, A.C. Roberts, and T.B. Kinney. Informatics in Radiology: developing a touchless user interface for intraoperative image control during interventional radiology procedures. RadioGraphics, 33(2):E61-70, Mar. 2013. doi: 10.1148/rg.332125101.

[7] V. Pavlovic, R. Sharma, and T. Huang. Visual Interpretation of Hand Gestures for Human-Computer Interaction: a Review. IEEE Transactions on Pattern Analysis and Machine Intelligence, 19(7):677-695, Jul. 1997. doi: 10.1109/34.598226.

[8] 王國榮。「基於資料手套的智慧型手勢辨識之廣泛研究」。臺灣科技大學電機工程系碩士論文，民國 90 年。

[9] J. Davis and M. Shah. Visual gesture recognition. Proc. of IEE on Vision, Image and Signal Processing, vol.141, pp.101-106, Apr. 1994.

[10] C.L. Huang and S.H. Jeng. A model-based hand gesture recognition system. Machine Vision and Applications, vol.12, pp.243-258, 2001.

[11] L. Gupta and M. Suwei. Gesture-based interaction and communication: automated classification of hand gesture contours. IEEE Transactions on Systems, Man, and Cybernetics, Part C: Applications and Reviews, vol. 31, pp. 114-120, 2001.

[12] W. Du and H. Li. Vision based gesture recognition system with single camera. Proc. of 5th International Conference on Signal Processing (ICSP2000), vol.2, pp.1351-1357, 2000.

[13] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, F. Zhang, C.L. Chang, M.G. Yong, J. Lee, W.T. Chang, W. Hua, M. Georg, and M. Grundmann. Mediapipe: A framework for building perception pipelines. Jun. 2019. https://doi.org/10.48550/arXiv.1906.08172

[14] A. Vakunov, C.L. Chang, F. Zhang, G. Sung, M. Grundmann, and V. Bazarevsky. MediaPipe Hands: On-device Real-time Hand Tracking. CVPR Workshop on Computer Vision for Augmented and Virtual Reality, 2000.

[15] L. Chandwani, J. Khilari, K. Gurjar, P. Maragale, A. Sonare, S. Kakade, A. Bhatt, and R. Kulkarni Gesture based Sign Language Recognition system using Mediapipe, June 2023. https://doi.org/10.21203/rs.3.rs-3106646/v1

[16] R. Kumar, A. Bajpai, and A. Sinha, Ayush. Mediapipe and CNNs for Real-Time ASL Gesture Recognition. 2023. https://doi.org/10.48550/arXiv.2305.05296

[17] B. Sundar and T. Bagyammal. American Sign Language Recognition for Alphabets Using MediaPipe and LSTM. Procedia Computer Science, 215:642–651, 2022. https://doi.org/10.1016/j.procs.2022.12.066

[18] Y. Kim. Convolutional Neural Networks for Sentence Classification. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP 2014), pp.1746–1751, 2014.

[19] S. Hochreiter and J. Schmidhuber. Long Short-term Memory. Neural Computation. 9:1735-80, 1997. doi: 10.1162/neco.1997.9.8.1735.

[20] DICOM Library. https://www.dicomlibrary.com/